

Rilevamento di Attacchi DDoS nel Traffico di Rete: Un Approccio basato su Decision Tree

1 Introduzione e Descrizione del Problema

La sicurezza delle reti informatiche è una delle sfide cruciali dell'era digitale. Tra le minacce più comuni e devastanti vi sono gli attacchi DDoS (Distributed Denial of Service), che mirano a rendere inaccessibile un servizio inondando il server bersaglio con una quantità massiccia di traffico anomalo. L'obiettivo di questo progetto è risolvere un problema di classificazione binaria in ambito cybersecurity: sviluppare una pipeline di Machine Learning in grado di analizzare il traffico di rete e distinguere autonomamente i pacchetti normali (Benign) da quelli malevoli (DDoS).

2 Descrizione dei Dati

Per l'addestramento e la valutazione del modello è stato utilizzato il dataset CICIDS2017, uno standard accademico di riferimento per i sistemi di rilevamento delle intrusioni. Nello specifico, è stato analizzato il traffico relativo alla giornata di venerdì (Friday-Working Hours), notoriamente ricca di attacchi DDoS. Il dataset originale si presenta in formato tabellare con 225.745 istanze e 79 colonne (feature) che descrivono statistiche avanzate del flusso di rete (es. durata del flusso, dimensione media dei pacchetti, tempo di inter-arrivo, ecc.).

L'analisi esplorativa preliminare ha evidenziato una distribuzione del target così composta:

- **DDoS**: 128.027 istanze (56,7%)
- **BENIGN**: 97.718 istanze (43,3%)

A differenza di molti scenari di cybersecurity fortemente sbilanciati, questo specifico sottoinsieme risulta sostanzialmente bilanciato, un dettaglio che ha guidato le successive scelte metodologiche di pre-processing.

3 Pre-processing e Feature Engineering

I dati estratti da reti reali sono intrinsecamente rumorosi. Il pre-processing si è articolato in diverse fasi strategiche:

- **Data Cleaning:** Sono stati individuati e rimossi 68 valori anomali (NaN e Infiniti) per garantire la stabilità numerica degli algoritmi.
- **Train/Test Split:** Il dataset è stato suddiviso in un set di addestramento (70%) e uno di test (30%). È stato utilizzato uno split stratificato per mantenere inalterata la proporzione tra le classi in entrambi i set.
- **Resampling (Non Applicato):** Data la natura bilanciata del sottoinsieme (56% vs 44%), si è scelto di non applicare tecniche di oversampling (es. SMOTE) per evitare l'introduzione di rumore e preservare l'integrità del dato originale.
- **Feature Selection (Filter Method):** Le 78 feature originali esponevano il modello al rischio di overfitting e inefficienza computazionale. Utilizzando SelectKBest con la metrica `mutual_info_classif` (Information Gain), la dimensionalità è stata ridotta alle 20 feature più rilevanti. Tra queste sono emerse caratteristiche tipiche degli attacchi DDoS, come la dimensione totale e media dei pacchetti (es. Total Length of Fwd Packets, Average Packet Size), confermando la validità statistica della selezione.

4 Algoritmo Utilizzato e Ottimizzazione

Per affrontare il task è stato scelto l'algoritmo Decision Tree Classifier. Questo modello offre un eccellente compromesso tra potenza predittiva, interpretabilità e spiegabilità, permettendo di tracciare regole decisionali chiare.

I parametri del modello sono stati ottimizzati tramite GridSearchCV, utilizzando una Cross-Validation stratificata a 5 fold sul set di addestramento. La scelta di ottimizzare i parametri tramite Grid Search garantisce che l'albero non impari a memoria i dati. I parametri vincenti selezionati dall'algoritmo sono stati:

- `criterion = 'entropy'`: Allineato perfettamente con la feature selection precedente (Mutual Information), l'entropia si è rivelata la metrica migliore per massimizzare la purezza dei nodi.

- `max_depth = 15`: Una profondità adeguata per catturare la complessità dei dati senza degenerare in alberi infiniti e sovradattati.
- `min_samples_split = 2`: Consente una ramificazione fine, utile per separare con precisione gli ultimi campioni residui.

5 Metodo di Valutazione e Metriche

Per valutare il modello sono state utilizzate le metriche standard per la classificazione: Accuracy, Precision e Recall. Tuttavia, il modello è stato ottimizzato e valutato principalmente sull’F1-Score (media armonica tra Precision e Recall). In ambito sicurezza informatica, l’F1-Score è considerato il gold standard poiché penalizza pesantemente i modelli che generano troppi falsi allarmi o che mancano di rilevare minacce reali.

6 Risultati e Commenti

Le performance ottenute sul Test Set sono eccellenti:

- **Accuracy:** 0.9998
- **Precision:** 0.9999 (DDoS) / 0.9996 (BENIGN)
- **Recall:** 0.9997 (DDoS) / 0.9999 (BENIGN)
- **F1-Score (Macro Avg):** 0.9998

Il modello rasenta la perfezione predittiva (99,98%). Sebbene valori così alti possano suggerire un sospetto di overfitting, l’affidabilità del risultato è garantita da due fattori chiave:

1. La rigorosa validazione incrociata applicata in fase di addestramento (dove l’F1-score era identico al Test set).
2. La natura stessa dell’attacco DDoS: inondando la rete con pacchetti anomali per volume e frequenza, l’attacco lascia una ”firma” matematica nettamente distinguibile rispetto al traffico organico.

L’albero decisionale ha isolato con successo queste firme, minimizzando i falsi positivi e i falsi negativi, come evidente dalla Matrice di Confusione generata a valle dell’esperimento.